IA & APP
S&P 500

ANDRE Victor - BOGAER Youenn - DANO Ewen

Sommaire

1. Introduction et contexte - p3
2. Data - p4
3. MLOPS - p8
4. Modèle : XGBoost - p10
5. Implémentation - p11
6. Résultats - p15
7. Conclusion - p18

STANDARD & POOR'S

CY TECH sciences et techniques

Contexte

- L'indice S&P 500 représente les 500 plus grandes entreprises américaines, soit plus de 61 000 milliards d'USD de capitalisation.

- Battre cet indice sur le long terme est considéré comme l'un des problèmes les plus difficiles en finance en raison de sa volatilité et de sa croissance structurelle.

CY TECH
sciences
et techniques

Data - Tâche ML

- Classification binaire
  - Targets: évolution + ou - du cours sur un horizon *n* jours.

- Régression
  - Prédiction des performances du cours sur un horizon *n* jours.
  - Tâche complexe car cours très bruité

horizons 5-20 jours pour réduire le bruit

⇒ On se concentrera sur la classification

CY TECH sciences et techniques

Data

- De 2000 à aujourd'hui
- Issus de la federal reserve
- Environ 6 500 lignes
- Données stockées sous parquet

- Eviter le data leakage !!

Exemple de Features

Feature	Explication	Horizon
Volatility	Mesure variations des prix	Court terme
Fed_rate	Taux intérêt banque centrale	Long terme
Inflation_var	Variation de l'inflation	Moyen/Long terme
Dist_SMA_10	Ecart entre le prix et la moyenne des 10 derniers jours.	Court terme
Dist_SMA_200	Idem que Dist_SMA_10 pour 200 jours	Long terme
RSI	Indique si le marché est suracheté ou survenddu	court terme
…	+ 8 autres	…

CY TECH sciences et techniques

Features importantes

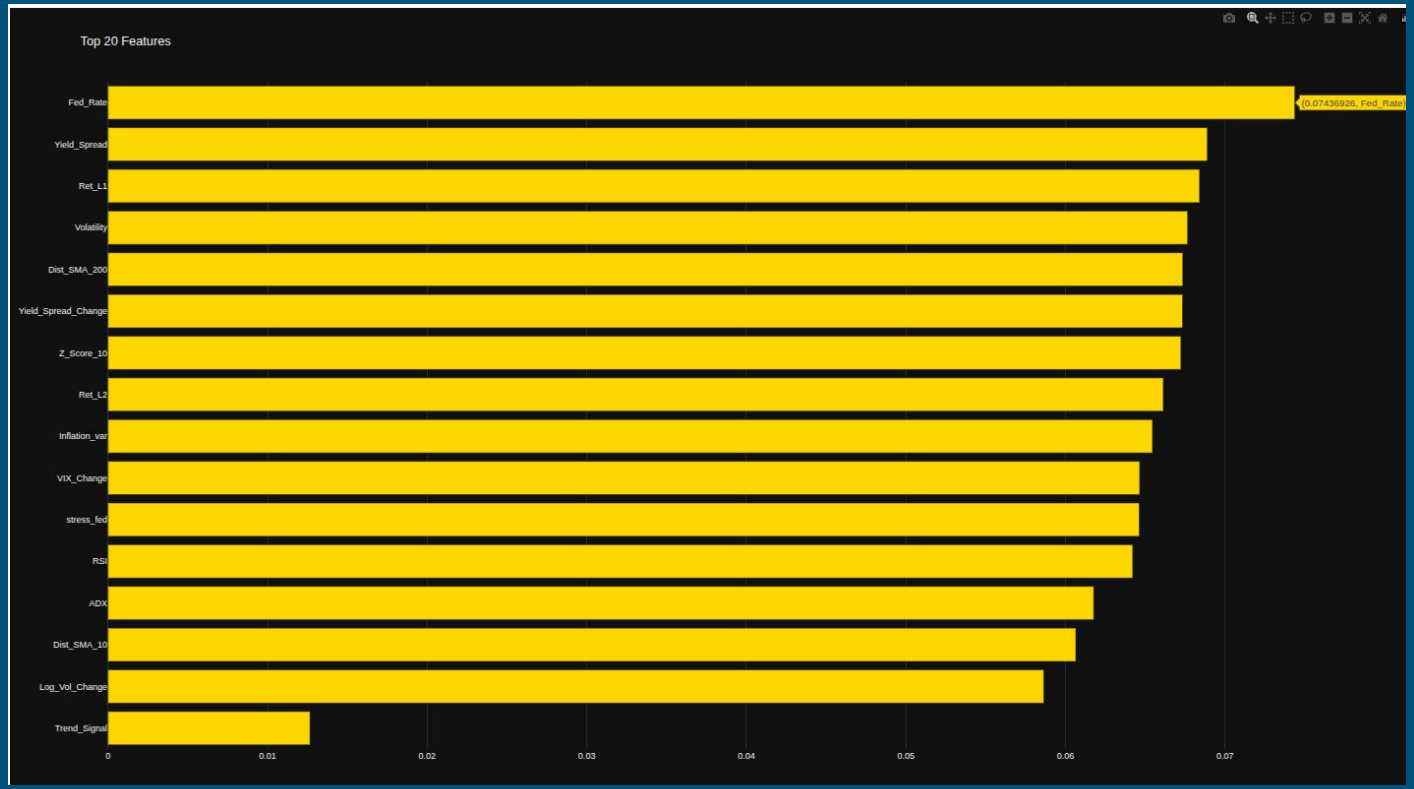

Infrastructure MLOPS

- **Kedro** : Modularité du pipeline (Nodes & Pipelines) pour une reproductibilité totale.
- **MLFlow** : Suivi des runs, archivage des hyperparamètres et gestion des versions de modèles.
- **Optuna** : Optimisation automatisée des hyperparamètres via Grid Search intelligent.

CY TECH sciences et techniques

Modèle : XGBoost

- **Boosting Séquentiel :** Chaque arbre corrige les erreurs du précédent.
- **Régularisation :** Paramètres Alpha/Lambda pour pénaliser la complexité extrême.
- **Élagage (Pruning) :** Ne garde que les branches ayant une importance prédictive réelle.

- Surperforme Random Forest

CY TECH sciences et techniques

Xgboost - hyperparamètres

- Validation : TimeSeriesSplit à 5 plis
- 400 essais
- Complexité : Profondeur d'arbres faible et learning rate réduit.
- Régularisation : Paramètres alpha et lambda maintenus à des valeurs faibles.

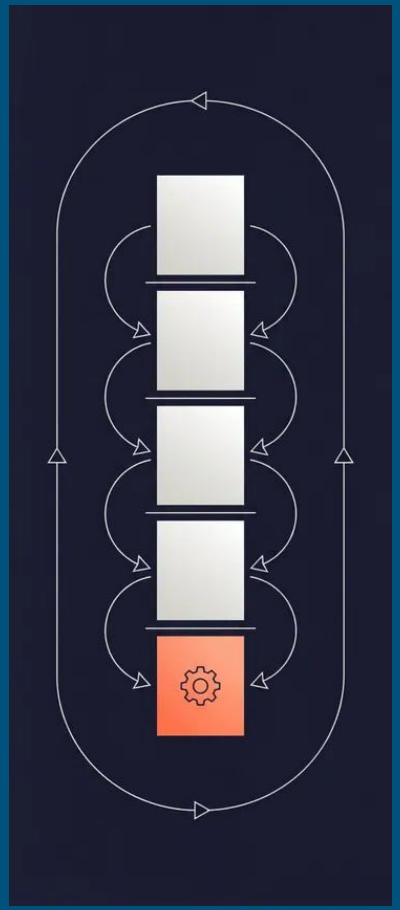

CY TECH sciences et techniques

Fiabilité des données

Vu l'enjeu économique d'un tel modèle, nous avons besoin de prédictions fiables

Méthodes :

- Sigmoïde : Validation croisée à 5 plis pour calibrer les scores.
- Gestion du Déséquilibre : Correction du biais haussier structurel du marché

CY TECH sciences et techniques

CY TECH sciences et techniques

Seuils de décision

- Le modèle ne doit pas choisir en cas d'incertitude.
- tests sur différents seuil de probabilités
- Comme une cross validation
- 3 "modes" possibles :
  - Achat
  - neutre
  - short

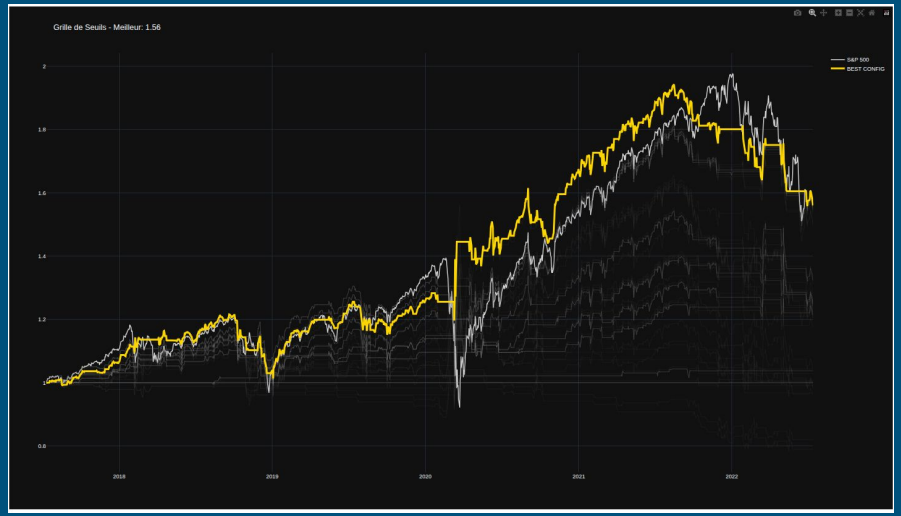

Métriques

- MCC :

$$MCC = \frac{VP \times VN - FP \times FN}{\sqrt{(VP+FP)(VP+FN)(VN+FP)(VN+FN)}}$$

- Rendement

- Sharpe Ratio

$$S = \frac{R_p - R_f}{\sigma_p}$$

- Ratio de Sortino

CY TECH sciences et techniques

Résultats

- Rendement final :
- 169% de rendement contre 156% (celui du marché)
  - Surperformance de 13 points

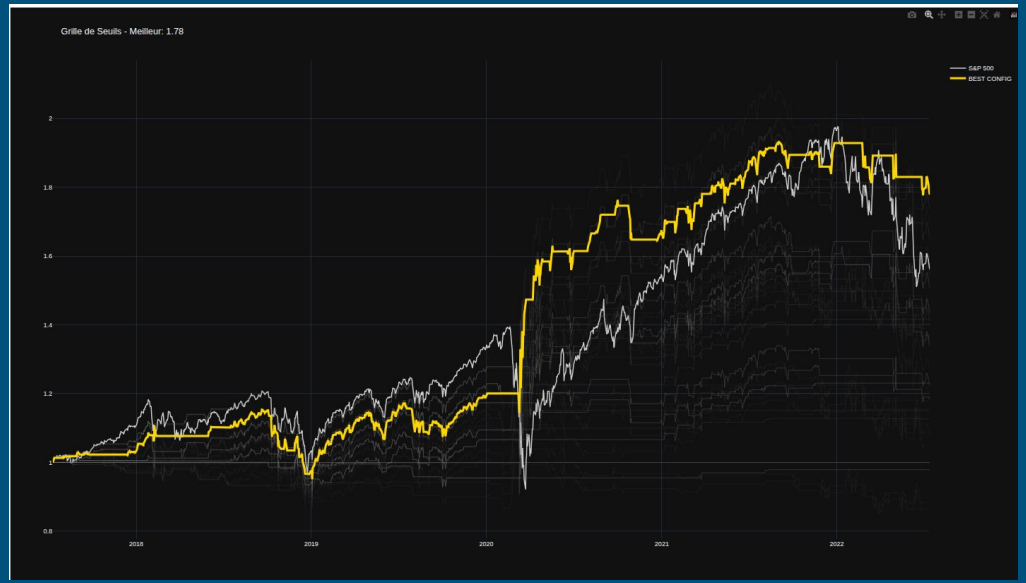

- Gestion du risque
- Ratio de Sharpe : 1.07
- Ratio de Sortino : 1.28

CY TECH
sciences
et techniques

Résultats

Analyse des métriques de classification :

- Rappel : 85 %
  - Bonne détection des montées
- Précision : 60 %
  - Erreur parfois
- MCC : 2 %
  - faible mais classique en finance
- Rendement 1.

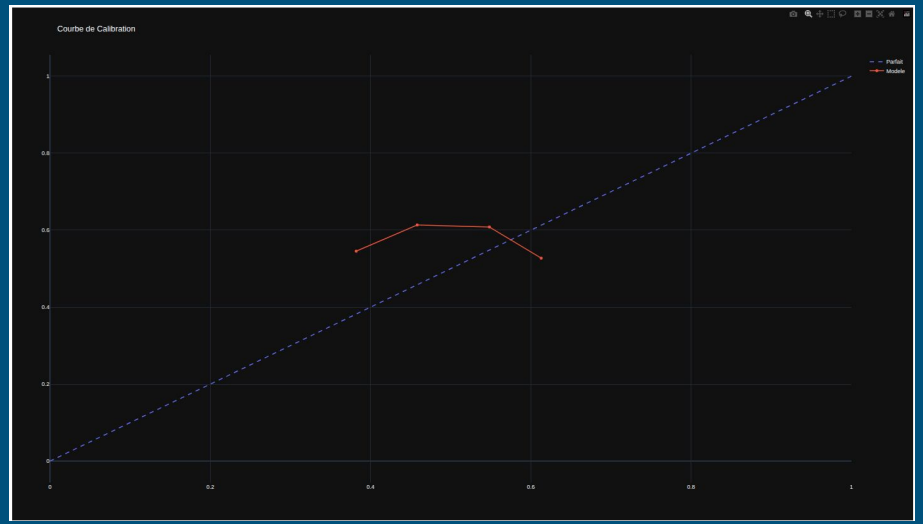

CY TECH sciences et techniques

Conclusion

Limites :

- Non, nous n’allons pas faire fortune grâce à ce modèle :/
- Sur d’autres période, le modèle sous performe
- Dans la réalité : frais à chaque transaction

CY TECH sciences et techniques

Bonus

Nous avons fait une API avec Streamlit pour entraîner de nouveaux modèles, obtenir et présenter des prédictions.